

Отчёт по лабораторной работе «Оценка оригинальности текста методом ШИНГЛОВ»

1. Исходный текст (оригинал)

«В **последние** годы **технологии** машинного обучения **достигли невероятных** высот. **Разработчики создают умные** системы, которые **способны распознавать** речь, **анализировать** изображения и даже управлять автомобилями.

Современные нейронные сети требуют **огромных вычислительных** мощностей, однако результаты их **работы впечатляют** как ученых, так и обычных пользователей.

Глубокое обучение стало **основой** для создания **генеративных** моделей, которые **умеют** писать тексты, **рисовать** картины и сочинять музыку.

Компании по всему миру **активно инвестируют** в **развитие** искусственного интеллекта,

понимая его огромный **потенциал** для автоматизации бизнес процессов.

Однако вместе с прогрессом возникают и серьезные этические вопросы, связанные с конфиденциальностью данных и заменой человеческого труда роботами.

Эксперты прогнозируют что в ближайшие десять лет искусственный интеллект полностью изменит рынок труда и повседневную жизнь миллионов людей.»

Жирным выделены **24 слова**, которые будут заменены синонимами.

2. Текст после канонизации

Приведение к нижнему регистру, удаление знаков препинания (. ,), замена переносов строк пробелами:

в последние годы технологии машинного обучения достигли невероятных высот разработчики создают умные системы которые способны распознавать речь анализировать изображения и даже управлять автомобилями современные нейронные сети требуют огромных вычислительных мощностей однако результаты их работы впечатляют как ученых так и обычных пользователей глубокое обучение стало основой для создания генеративных моделей которые умеют писать тексты рисовать картины и сочинять музыку компании по всему миру активно инвестируют в развитие искусственного интеллекта понимая его огромный потенциал для автоматизации бизнес процессов однако вместе с прогрессом возникают и серьезные этические вопросы связанные с конфиденциальностью данных и заменой человеческого труда роботами эксперты прогнозируют что в ближайшие десять лет искусственный интеллект полностью изменит рынок труда и повседневную жизнь миллионов людей

3. Модифицированный текст

3.1. Таблица замен (24 замены)

Оригинал	Замена
последние	минувшие
технологии	методы
достигли	добились
невероятных	немыслимых
разработчики	программисты
создают	проектируют
умные	интеллектуальные
способны	могут
распознавать	понимать
анализировать	обрабатывать
огромных	больших
вычислительных	серверных
работы	функционирования
впечатляют	поражают
глубокое	многоуровневое
основой	фундаментом
генеративных	порождающих
умеют	способны
рисовать	создавать
компании	корпорации
активно	усиленно
инвестируют	вкладывают
развитие	продвижение
потенциал	перспективы

3.2. Перестановки слов

Дополнительно произведены перестановки соседних слов на позициях:

- 5 ↔ 6 (обучения ↔ добились)
- 15 ↔ 16 (понимать ↔ речь)
- 30 ↔ 31 (однако ↔ результаты)
- 50 ↔ 51 (способны ↔ писать)

3.3. Итоговый модифицированный текст

в **минувшие** годы **методы** машинного **добились** обучения **немыслимых** высот **программисты проектируют интеллектуальные** системы которые **могут** речь **понимать обрабатывать** изображения и даже управлять автомобилями современные нейронные сети требуют **больших серверных** мощностей результаты **однако их функционирования поражают** как ученых так и обычных пользователей **многоуровневое** обучение стало **фундаментом** для создания **порождающих** моделей которые писать **способны** тексты **создавать** картины и сочинять музыку **корпорации** по всему миру **усиленно вкладывают** в **продвижение** искусственного интеллекта понимая его огромный **перспективы** для автоматизации бизнес процессов однако вместе с прогрессом возникают и серьезные этические вопросы связанные с

конфиденциальностью данных и заменой человеческого труда роботами эксперты прогнозируют что в ближайшие десять лет искусственный интеллект полностью изменит рынок труда и повседневную жизнь миллионов людей

Жирным выделены изменённые/переставленные слова. Сделано замен: **24**, перестановок: **4**.

4. Технологический стек

В качестве генератора шинглов была выбрана библиотека `binascii` со способом хеширования **CRC32**.

Причины выбора CRC32:

- **Скорость** — в методе шинглов необходимо вычислить сотни или тысячи хешей (по одному на каждый шингл), поэтому скорость алгоритма выходит на первый план.
- **Компактность** — CRC32 генерирует 32-битное целое число.
- **Достаточная уникальность** — для задач поиска дубликатов CRC32 обеспечивает достаточную уникальность отпечатков, сводя к минимуму риск коллизий.

5. Параметры текста и шинглов

Параметр	Значение
Всего слов в оригинальном тексте	112
Всего слов в модифицированном тексте	112
Выбранный шаг шингла (длина)	3
Количество шинглов в первом тексте	110
Количество шинглов во втором тексте	110
Количество совпадающих контрольных сумм	55
Отличительных контрольных сумм	110

6. Контрольные суммы шинглов

6.1. Шинглы оригинального текста (первые 14 из 110)

№	Хеш	Слова
1	939096183	в последние годы
2	2553108029	последние годы технологии
3	4177627857	годы технологии машинного
4	2261648803	технологии машинного обучения
5	3311943976	машинного обучения достигли
6	2335645124	обучения достигли невероятных
7	4143053757	достигли невероятных высот
8	2594497386	невероятных высот разработчики

9 2178852320 высот разработчики создают
10 624746719 разработчики создают умные
11 1270172934 создают умные системы
12 3600406843 умные системы которые
13 3526545144 системы которые способны
14 4251675046 которые способны распознавать

6.2. Шинглы изменённого текста (первые 14 из 110)

№	Хеш	Слова
1	2669976926	в минувшие годы
2	3382335633	минувшие годы методы
3	3259079717	годы методы машинного
4	2115515090	методы машинного добились
5	1767917631	машинного добились обучения
6	571932938	добились обучения немыслимых
7	1020753351	обучения немыслимых высот
8	890537038	немыслимых высот программисты
9	3269545682	высот программисты проектируют
10	3529992562	программисты проектируют интеллектуальные
11	2443772388	проектируют интеллектуальные системы
12	3545195596	интеллектуальные системы которые
13	2611148557	системы которые могут
14	1815553023	которые могут речь

Все первые 14 шинглов **различаются** — замены и перестановки затронули начало текста наиболее плотно.

7. Результаты оригинальности

Метрика	Значение
Количество шинглов в первом тексте	110
Количество совпадающих шинглов	55
Сходство текстов	50.00%
Оригинальность	50.00%

8. Таблица для различной длины шинглов

Длина шингла	Кол-во шинглов	Совпадения	Сходство, %	Оригинальность, %
1	112	77	68.75	31.25
2	111	65	58.56	41.44
3	110	55	50.00	50.00
4	109	49	44.95	55.05
5	108	44	40.74	59.26
6	107	40	37.38	62.62

8	105	35	33.33	66.67
---	-----	----	-------	-------

С ростом длины шингла процент сходства закономерно уменьшается, так как вероятность полного совпадения более длинных последовательностей слов снижается.

9. Сравнение с внешней системой антиплагиата

9.1. Результаты программы

Основаны на сравнении CRC32-хешей последовательностей слов. Не учитывают контекст и семантику.

9.2. Результаты системы lastotchkin.ru

По данным сайта [lastotchkin.ru \(http://www.lastotchkin.ru/ra/index.php\)](http://www.lastotchkin.ru/ra/index.php):

Длина шингла Сходство, % Оригинальность, %

1	49.25	50.75
2	30.59	69.41
3	16.40	83.60
4	9.55	90.45

9.3. Сравнительный анализ

Длина шингла Сходство (программа), % Сходство (lastotchkin), % Разница, п.п.

1	68.75	49.25	+19.50
2	58.56	30.59	+27.97
3	50.00	16.40	+33.60
4	44.95	9.55	+35.40

Расхождения обусловлены различиями в:

- **предобработке текста** (стемминг, лемматизация, удаление стоп-слов);
- **алгоритмах хеширования** и формирования шинглов;
- **метриках расчёта** сходства (Жаккар vs. доля от общего числа).

Несмотря на количественные расхождения, обе системы демонстрируют **одинаковую закономерность**: с ростом длины шингла процент сходства уменьшается. Это соответствует теоретическим основам метода и подтверждает работоспособность разработанного алгоритма.

10. Вывод

Метод шинглов позволяет оценить уникальность текста путём поиска точных совпадений последовательностей слов. Чем больше длина шингла, тем более строгим становится критерий проверки.

Для двух текстов (оригинального и модифицированного с помощью 24 синонимических замен и 4 перестановок слов) при длине шингла, равной **3**, было получено **55 совпадений** из **110** возможных.

Рассчитанная оригинальность составила **50.00%**. Это означает, что, несмотря на внесённые изменения, текст в значительной мере сохраняет свою структуру на уровне трёхсловных фрагментов — вторая половина текста (начиная с позиции ~72) практически не затронута заменами, что и обеспечило высокую долю совпадений.

Полученный методом шинглов результат является лишь одной из оценок. Современные системы антиплагиата («Антиплагиат.ру», «Рукоконтекст») используют более сложные алгоритмы, включающие анализ синонимов, морфологии и семантики, поэтому их процент оригинальности может отличаться.

Метод шинглов **прост в реализации и эффективен для поиска точных копий** и незначительных изменений текста, но уступает более сложным системам в выявлении глубокого рерайта и смыслового заимствования.